[코랩(Colab) 실습 공통 규칙 · 2026-10-15]

[MBC 미디어캠퍼스] AI 기반 데이터 저널리스트 양성 과정

코랩 CSV 파일 생성 규칙

원자료 → 정제 → 교차검증, 세 종류의 CSV 를 구분해서 만드는 이유와 방법

1. 이 규칙이 필요한 이유

코랩에서 API 로 데이터를 받으면, 분석에 필요한 일부만 추출해 CSV 로 저장하고 싶은 유혹이 생긴다. 하지만 이렇게 하면 나중에 다른 지표(예: 차트에만 등장하고 표로는 남기지 않은 값)가 필요할 때 API 를 다시 호출하거나 차트를 보고 어림짐작해야 하는 문제가 생긴다. 또한 CSV 를 AI 챗봇(스크립트화 단계)에 넘길 때, 파일 하나에 "원자료 그대로의 값"과 "정제된 값"이 섞여 있으면 AI 가 지역코드 같은 원본 코드값을 통계 수치로 착각해 기사에 잘못 쓰는 "사실 혼합" 오류가 생길 수 있다. 그래서 코랩에서 CSV 를 만들 때는 아래 두 가지 규칙을 반드시 지킨다.

2. 규칙 ① — 용도별 파일명을 구분한다

접미사	의미	용도
***_raw.csv**	API 가 돌려준 원자료 그대로 — 지역코드·ITM_ID 등 원본 컬럼 포함, 가공 없음	보관용. 나중에 다른 지표가 필요할 때 다시 API 를 호출하지 않고 이 파일에서 꺼내 쓴다
***_clean.csv** 또는 ***_final.csv**	정제 완료 — 결측치 처리·컬럼 정리까지 끝나서 AI 챗봇(스크립트화 단계)에 소재로 바로 투입 가능	③ 정제 단계의 최종 산출물. ⑤ 스크립트화 단계의 AI 챗봇에 이 파일만 첨부한다
***_crosscheck.csv**	교차검증용 중간 결과 — 참고자료일 뿐, AI 에게 소재로 주지 않는다	⑥ 팩트체크 단계에서 사람 또는 코드가 대조할 때만 쓴다

예: one_person_household_raw.csv → one_person_household_clean.csv → (필요시) one_person_household_crosscheck.csv

3. 규칙 ② — API 응답은 항상 전체를 먼저 raw 로 저장한다

API URL 을 호출했을 때 돌아오는 전체 항목(전체 컬럼·전체 지표)을 빠짐없이 먼저 *_raw.csv 로 통째로 저장한다. 분석에 필요한 일부만 뽑아서 저장하는 것은 그 다음 단계(clean·final)에서 한다.

순서: API 호출 → 전체 응답을 *_raw.csv 로 저장 → 분석 목적에 맞게 추출·가공 → *_clean.csv 또는 *_final.csv 로 저장

4. 규칙 ③ — 컬럼 정의를 함께 남긴다

CSV 상단 주석이나 별도 설명(텍스트 셀 출력 등)에 각 컬럼이 무엇을 뜻하는지 정의를 남긴다. 특히 지역코드·ITM_ID 처럼 숫자처럼 보이지만 통계값이 아닌 컬럼은 반드시 표시한다. 이렇게 해야 AI 챗봇이 정제데이터를 기사로 쓸 때 원자료의 코드값을 통계 수치로 착각해 섞어 쓰는 "사실 혼합" 오류를 막을 수 있다.

5. 코랩 코드 예시

아래는 세 규칙을 적용한 최소 예시다. 실제 실습에서는 API 응답 구조에 맞게 컬럼명을 바꿔 쓴다.

```
# 1) API 호출 — 전체 응답을 그대로 받는다
import pandas as pd, requests
res = requests.get(API_URL, params=params).json()
df_raw = pd.DataFrame(res["items"])  # 반환된 모든 컬럼 포함

# 2) raw 저장 — 가공 없이 원자료 그대로
df_raw.to_csv("one_person_household_raw.csv", index=False, encoding="utf-8-sig")

# 3) 정제 — 분석 목적에 맞게 컬럼 선택·결측치 처리
df_clean = df_raw[["지역", "연도", "비중"]].dropna()

# 4) clean 저장 + 컬럼 정의 주석을 별도 텍스트로 함께 남긴다
df_clean.to_csv("one_person_household_clean.csv", index=False, encoding="utf-8-sig")
print("컬럼 정의: 지역=시도명(코드 아님), 연도=조사연도, 비중=1인가구 비중(%)")
```

6. 이 규칙이 들어가는 전체 작업 흐름

단계	파일	하는 일
② 수집	*_raw.csv	API 전체 응답을 가공 없이 저장
③ 정제	*_clean.csv / *_final.csv	분석 목적에 맞게 추출·가공, 컬럼 정의 명시
⑤ 스크립트화	(clean/final 투입)	AI 챗봇에 정제데이터만 첨부해 대본 초안 작성
⑥ 팩트체크	*_crosscheck.csv + raw/clean 대조	대본 속 숫자를 raw·clean 데이터와 코드로 자동 대조

7. 체크리스트

- API를 호출하면 전체 응답을 가공 없이 *_raw.csv로 먼저 저장했는가
- 분석용으로 추출·가공한 결과는 *_clean.csv 또는 *_final.csv라는 이름으로 따로 저장했는가
- AI 챗봇(스크립트화 단계)에는 raw가 아니라 clean/final 파일만 첨부했는가
- 컬럼 정의(특히 코드값 컬럼)를 주석이나 출력문으로 남겼는가
- 교차검증용 중간 결과는 *_crosscheck.csv로 구분해, AI에게 소재로 주지 않았는가