MBC 미디어캠퍼스 · AI 기반 데이터 저널리스트 양성 과정

3 주차

도메인에 맞는 뉴스 세팅하기 (2/3)
데이터 수집과 정제, 직접 해보기

② 수집 (구글시트 + Colab API) → ③ 정제 (AI 챗봇) 순서로 실습합니다

③ 도메인에 맞는 뉴스 세팅하기 120h 중 2/3(40h)

ORIENTATION

오늘의 학습 목표

01

수집 실습 : 시트와 코드

AI 검색의 한계를 확인하고 , 구글시트 함수와 Colab API 호출 코드 (AI 와 함께 작성 · 실행) 로 직접 수집한다

02

AI 챗봇 정제 실습

2 주차에 만든 도메인 챗봇 (Gemini Gems·Claude Projects) 으로 수집한 원자료를 다듬어 콘텐츠로 완성한다

03

파이프라인 연결

수집→정제가 실제로 어떻게 이어지는지 손으로 직접 확인한다

PIPELINE 복습

이번주는 ②③단계를 직접 해봅니다

① 기획 → **② 수집**
구글시트 IMPORTXML
파이썬 (Colab)
→ **③ 정제**
표 : 시트 함수 ·Colab
글 : 2 주차 도메인 챗봇
→ ④ 인사이트 분석 → ⑤ 팩트체크 → ⑥ 스크립트화 → ⑦ 영상화

2 주차에서 개념으로 배운 두 단계를 , 이번주는 실제 데이터로 손을 움직여 직접 실습합니다 .

왜 AI 검색이 아니라 직접 수집하는가

AI 검색은 답을 요약 · 재서술해서 보여 줍니다 . 그 과정에서 틀릴 수 있습니다 — 오늘 직접 비교해 확인합니다 .
직접 수집은 원문을 그대로 가져오고 출처 · 수집일시가 남아 , 오류가 생겨도 어디서 틀렸는지 점검할 수 있습니다 .
AI 검색은 후보를 찾는 용도 , 직접 수집은 근거를 확보하는 용도입니다 .

검색 ① · 출처

어디서 찾을까 — 출처는 3 가지로 나눈다

1	**1 차 출처**	법령 · 판결 · 통계 · 공식 발표 — 근거는 여기서 확인한다
2	**언론 보도**	맥락 · 현황 파악용 — 날짜와 원문 링크를 함께 확인한다
3	**해설 ·SNS· 커뮤니티**	단서로만 사용 — 반드시 1 차 출처로 되짚어 확인한다

AI 검색, 질문은 이렇게

1	**한 문장으로**	무엇을 알고 싶은지 한 문장으로 쓴다 (기획서의 What)
2	**기간 · 범위 정하기**	‘ 최근 1 년’ , ‘ 한국’처럼 기준 날짜와 범위를 적는다
3	**출처 요구**	출처 유형 (공식 기관 · 언론) 과 링크를 함께 달라고 한다
4	**모르면 모른다고**	확실하지 않은 내용은 ‘확인 불가’로 표시하게 한다
5	**사실과 해석 구분**	답은 출처를 열어 확인하기 전까지 ‘후보’일 뿐이다

AI 검색 도구 3 종과 프롬프트 예시

Perplexity

문장마다 번호 출처 · 포커스 모드 (웹 · 학술 등)

Liner (라이너)

답변 문장별 출처 · 학술논문 · 기간 필터

Felo (펠로)

최신 정보 수집 · 다국어 지원

프롬프트 예시

[내 주제] 에 대해 최근 1 년 이내 자료만 찾아줘 .
공식 기관 · 언론 출처를 링크와 함께 표로 정리하고 , 확실하지 않은 내용은 '확인 불가'로 표시해줘 .

※ 도구는 후보를 찾아 줄 뿐 , 사실을 보증하지 않습니다 .

예시 — 같은 질문, 이렇게 확인한다

입력한 질문
2026 년 적용 최저임금에 대해 최근 1 년 이내 자료만 찾아줘. 공식 기관·언론 출처를 링크와 함께 표로 정리하고, 확실하지 않은 내용은 '확인 불가'로 표시해줘.

확인 항목	검색에서 나온 내용	출처 (날짜)	내가 확인한 것
시간급	10,320 원 (전년 대비 2.9% 인상)	언론 보도 (2025.7.11)	보도마다 같은 숫자 ✔️
월 환산액	2,156,880 원	언론 보도 (2025.7.11)	10,320 원 × 209 시간 = 2,156,880 원 ✔️ 직접 계산
적용 연도	같은 검색에 2027 년 적용 10,700 원도 함께 나옴	언론 보도 (2026.7.15)	연도가 섞임 — 2026 년 적용분과 2027 년 적용분을 구분
공식 출처	고용노동부 보도자료·고시 페이지가 검색됨	고용노동부 누리집	본문은 열어서 직접 대조 (자동 접근 제한 사이트)

강의 준비 중 웹 검색으로 실행한 예시입니다 (2026.10.10). 도구와 시점에 따라 결과는 달라지므로, 오늘은 내 질문으로 직접 비교합니다.

검색 ⑤ · 함께 해보기

같은 질문을 세 도구에 넣고 함께 비교한다

1	**질문 쓰기**	내 아이템으로 질문 한 문장을 쓴다 — 방금 본 요령을 적용
2	**세 도구에 입력**	같은 질문을 Perplexity·Liner·Felo 에 그대로 넣는다
3	**기록하기**	도구별 답 · 출처 · 날짜를 기록표에 적는다
4	**직접 확인**	출처 링크를 열어 답이 실제로 있는지 , 날짜 · 수치가 맞는지 대조한다
5	**함께 정리**	도구마다 다른 점 , 틀린 점을 같이 찾아 발표한다

AI 검색으로 수집하면 부딪히는 한계

1	**요약하다 틀린다**	AI 는 원문을 요약 · 재서술해 보여 준다 — 그 과정에서 내용이 달라질 수 있다
2	**출처가 불안정하다**	링크와 내용이 맞지 않거나 , 홍보 · 블로그 글이 함께 섞인다
3	**매번 결과가 달라진다**	같은 질문도 실행할 때마다 달라져 같은 조건으로 재현할 수 없다
4	**날짜 · 연도가 섞인다**	오래된 자료나 다른 연도 자료가 함께 나온다 (예시 : 2026 년 ·2027 년 최저임금)
5	**원문과 기록이 남지 않는다**	원문 그대로 저장되지 않고 , 수집일시 기록과 표 정리 · 대량 수집이 어렵다

정리 — AI 는 후보를 찾고, 근거는 직접 수집한다

1	**AI 검색의 역할**	후보와 링크를 모으는 데까지 — 확인 전까지는 '단서'
2	**1 차 출처로 확인**	공식 사이트 · 원문에서 직접 대조한다 (⑤ 팩트체크)
3	**직접 수집**	원문을 그대로 가져오고 출처 · 수집일시를 남긴다 — 지금부터 실습

왜 구글시트로 수집하는가

코드 불필요

함수 하나 (=IMPORTXML) 만 셀에 입력하면 끝 — 별도 프로그램 설치 · 실행 없음

함께 직접 해보기

함께 URL 과 추출 위치 (XPath) 를 직접 찾아 입력 — 한 번 익히면 다른 페이지에도 응용 가능

결과가 바로 표 형태

수집한 데이터가 셀에 바로 채워져 정제 · 필터링이 쉬움

무료

구글 계정만 있으면 별도 비용 없이 사용 가능

IMPORTXML 함수 사용법

```
=IMPORTXML( url , xpath_query )
```

url 데이터를 가져올 웹페이지 주소 (따옴표로 감싸기)

xpath_query 페이지에서 추출할 위치를 지정하는 경로 — 크롬 개발자도구에서 요소 우클릭 → ‘ Copy XPath’ 로 얻을 수 있음

주의 : xpath 와 url 모두 큰따옴표 (") 로 감쌉니다 . 작은따옴표 (') 가 필요한 경우는 xpath 안에 속성값 (예 : @id=' 내용 ') 이 있어 따옴표가 또 필요할 때뿐입니다 — //h1 처럼 단순한 경로는 큰따옴표만으로 충분합니다 .

② 수집 · 흔한 오류와 한계

실습 중 자주 만나는 문제

#N/A 오류	xpath 가 실제 페이지 구조와 다름 — 페이지 구조가 바뀌었거나 요소 선택이 틀림
따옴표 오류	속성값이 있는 xpath(예 : [@id="…"]) 를 그대로 붙여넣어 큰따옴표가 겹칠 때 발생 — 안쪽만 작은따옴표로 교체 . 단순 경로 (//h1 등) 는 큰따옴표만 쓰면 됨
' 로드하는 데 시간이 걸림'	시간당 호출 제한 초과 — IMPORTXML 개수를 줄이거나 잠시 후 재시도
빈 결과	자바스크립트로 나중에 그려지는 동적 페이지 — IMPORTXML 은 정적 HTML 만 읽을 수 있음

② 수집 · 실전 확인

실전에서 확인한 사이트별 접근성

연합뉴스	차단	홈페이지 ·RSS 모두 자동 접근 차단 (robots.txt)
한국소비자원	차단	사이트 자동 접근 차단 — 시트 함수 대신 브라우저 기반 수집 (TOP5 자료) 으로 진행
정책브리핑 (korea.kr)	가능	실제 IMPORTXML 성공 , 텍스트 공공누리 자유이용
식품의약품안전처	가능	실제 접근 확인됨 , 리콜 · 안전 정보 다수
기상청 날씨누리	가능	공식 예보문 , 공공저작물

직접 테스트해보지 않으면 알 수 없습니다 — 같은 정부 사이트라도 차단 여부가 다릅니다 .

핵심 원칙

합법적 AI 데이터 활용 3 원칙

① 합법적 수집 구분 → ② AI 기반 정제 → ③ 사람의 검수

가능 — AI 로 자유롭게 정제

- 공공데이터포털 · 보도자료
- 증시 · 경기 등 사실 수치
- 위키백과 , 공유마당 (CCL)
- 본인이 직접 생산한 콘텐츠

제한 — 사실만 뽑아 내 문장으로

- 언론사 기사 본문 (AI 에 넣지 않기)
- 유료 구독 콘텐츠
- AI 학습 · 활용 금지 명시 저작물
- ‘ 변경금지’ 조건의 공공누리

② 수집 · 보조 함수

IMPORTHTML · IMPORTFEED 도 함께 알아두기

IMPORTHTML

`=IMPORTHTML(url, “table” 또는 “list”, 순번)`

페이지 안의 표나 목록을 통째로 가져올 때 — xpath 보다 훨씬 간단

IMPORTFEED

`=IMPORTFEED(url)`

언론사 · 블로그의 RSS 주소만 있으면 최신 글 목록을 자동 수집

② 수집 · 코딩으로 수집하는 이유

AI 검색이 아니라 코딩으로 수집하는 이유

요약 단계가 없다

원문 데이터를 그대로 가져온다 — 앞에서 본 요약 · 결론 오류가 구조적으로 생기지 않음

출처 · 수집일시 저장

어디서 언제 가져왔는지 열로 남겨 나중에 다시 확인할 수 있음

재현 가능

같은 코드를 다시 돌리면 같은 조건으로 같은 결과가 나옴

점검 가능

오류가 없어지는 것이 아니라 , 어디서 틀렸는지 찾아 고칠 수 있게 됨

코딩으로 수집하는 4 가지 방법

공식 API	포털 검색 API(네이버), 국가법령정보 · 공공데이터포털 — 가장 먼저 검토
RSS	언론사 · 기관이 제공하는 최신 글 목록 — 구조가 정해져 있어 안정적
웹 스크래핑	API·RSS 가 없을 때만 — robots.txt 와 이용약관을 먼저 확인
AI 검색 API	후보 발굴용 — 결과는 근거가 아닌 단서로 저장하고 원문과 대조

Colab 에서 API 로 데이터 가져오기

```
requests.get( url , headers= 헤더 , params= 조건 )
```

headers 인증키 (Client ID·Secret) — 코드에 직접 쓰지 않고 Colab 보안 비밀 (Secrets) 에 저장

params 검색어 (query), 가져올 건수 (display), 정렬 (sort) 등 — 응답은 JSON, 표 (DataFrame) 로 바꿔 저장

참고: 코드는 AI 와 함께 작성하되, 직접 실행해 결과를 확인합니다. 저장할 때 출처 URL· 수집일시 열을 꼭 추가합니다.

코딩 수집에서 지킬 4 가지

인증키 보관

코드에 직접 쓰지 않는다 — Colab 보안 비밀 (Secrets) 에 저장하고 공유 시 제외

호출 예의

호출 제한을 지키고 , 짧은 간격으로 반복 호출하지 않는다

약관 ·robots.txt

허용된 범위에서만 수집 — 기사 본문 등은 앞의 3 원칙 (저작권) 을 함께 확인

기록

출처 URL· 수집일시 · 검색 조건을 열로 남겨 팩트체크 때 다시 확인

② 수집 · API 키 발급 절차

학생별 API 키 발급, 이렇게 합니다

① 가입 · 본인 인증

네이버 개발자센터, 공공데이터포털, 국가법령정보 공동활용 — 서비스마다 각자 가입

② 등록 · 활용신청

사용할 API 를 고르고 사용 목적 입력 — 승인이 필요한 서비스는 사전에 신청

③ 키 확인

네이버 : Client ID·Secret / 공공데이터포털 : 인증키 (Encoding·Decoding) / 법령 : OC 값

④ 테스트 호출

Colab 에서 한 건만 호출해 응답 확인 — 안 되면 승인 상태 · 키 값 · 한도 순으로 점검

② 수집 · API 키 주의점

키는 내 비밀번호처럼 다룹니다

학생별 개별 발급

키는 개인 계정에 묶여 있음 — 공용 사용 · 타인에게 전달 금지

노출 금지

코드 · 슬라이드 · 공유 노트북에 직접 쓰지 않고 Colab 보안 비밀 (Secrets) 에 저장 , 유출 시 즉시 재발급

호출 한도

서비스마다 일일 한도가 있음 — 한 건으로 먼저 테스트하고 반복 호출에는 간격을 둔다

약관 · 개인정보

이용 약관 확인 , 수집 결과의 실명 등 개인정보는 필요한 항목만 저장 · 공유 전 점검

③ 정제 · 복습

정제란 무엇이었는지 복습

2 주차에서 만든 챗봇을 이번주는 실제 수집 자료로 돌려 봅니다.

Gemini Gems

무료 · 구글 계정

Claude Projects

Pro 이상 유료

이번주는 새로 만들지 않고 , 2 주차에 만든 내 도메인 챗봇에 ‘수집한 데이터’를 넣어 정제된 콘텐츠를 뽑아냅니다 .

② + ③ 연결

오늘 실습 흐름 — 수집에서 정제까지



2 주차 '도메인별 프롬프트 가이드'의 템플릿을 그대로 재사용합니다. (챗봇은 새로 만들지 않습니다)

오늘의 실습

수집 → 정제 , 손으로 직접 해보기

Part A. 구글시트로 지정된 페이지에서 데이터 수집하기
Part B. 저작권 유형을 확인한 뒤 , 2 주차 도메인 챗봇으로 정제해 콘텐츠 완성하기
Part C. Colab 에서 AI 와 함께 API 호출 코드를 작성 · 실행하고 , 결과표를 출처 · 수집일시와 함께 저장하기

다음 주 예고

4 주차 — 도메인에 맞는 뉴스 세팅하기 (3/3)
도메인별 파인튜닝 , AI 생성물 검수 · 품질개선 [③ 완료 120h]