3 주차

도메인에 맞는 뉴스 세팅하기 (2/3)
데이터 수집과 정제 , 직접 해보기

② 수집 (구글시트 + Colab API) → ③ 정제 (AI 챗봇) 순서로 실습합니다

③ 도메인에 맞는 뉴스 세팅하기 120h 중 2/3(40h)

ORIENTATION

오늘의 학습 목표

01

수집 실습 : 시트와 코드

AI 검색의 한계를 확인하고 , 구글시트 함수와 Colab API 호출 코드 (AI 와 함께 작성 · 실행) 로 직접 수집한다

02

AI 챗봇 정제 실습

2 주차에 만든 도메인 챗봇 (Gemini Gems·Claude Projects) 으로 수집한 원자료를 다듬어 콘텐츠로 완성한다

03

파이프라인 연결

수집→정제가 실제로 어떻게 이어지는지 손으로 직접 확인한다

PIPELINE 복습

이번주는 ②③단계를 직접 해봅니다

2 주차에서 개념으로 배운 두 단계를 , 이번주는 실제 데이터로 손을 움직여 직접 실습합니다 .

① 기획	→	② 수집	→	③ 정제	→	④ 인사이트 분석
		구글시트 IMPORTXML 파이썬 (Colab)		표 : 시트 함수 ·Colab 글 : 2 주차 도메인 챗봇		

⑤ 팩트체크	→	⑥ 스크립트화	→	⑦ 영상화

왜 AI 검색이 아니라 직접 수집하는가
AI 검색은 답을 요약 · 재서술해서 보여 줍니다 . 그 과정에서 틀릴 수 있습니다 — 오늘 직접 비교해 확인합니다 .
직접 수집은 원문을 그대로 가져오고 출처 · 수집일시가 남아 , 오류가 생겨도 어디서 틀렸는지 점검할 수 있습니다 .
AI 검색은 후보를 찾는 용도 , 직접 수집은 근거를 확보하는 용도입니다 .

어디서 찾을까 — 출처는 3 가지로 나눈다

1

1 차 출처

법령 · 판결 · 통계 · 공식 발표 — 근거는 여기서 확인한다

2

언론 보도

맥락 · 현황 파악용 — 날짜와 원문 링크를 함께 확인한다

3

해설 ·SNS· 커뮤니티

단서로만 사용 — 반드시 1 차 출처로 되짚어 확인한다

AI 검색, 질문은 이렇게

1	**한 문장으로** 무엇을 알고 싶은지 한 문장으로 쓴다 (기획서의 What)
2	**기간 · 범위 정하기** ‘ 최근 1 년’ , ‘ 한국’ 처럼 기준 날짜와 범위를 적는다
3	**출처 요구** 출처 유형 (공식 기관 · 언론) 과 링크를 함께 달라고 한다
4	**모르면 모른다고** 확실하지 않은 내용은 ‘확인 불가’ 로 표시하게 한다
5	**사실과 해석 구분** 답은 출처를 열어 확인하기 전까지 ‘후보’ 일 뿐이다

AI 검색 도구 3 종과 프롬프트 예시

Perplexity

문장마다 번호 출처 · 포커스 모드 (웹 · 학술 등)

Liner (라이너)

답변 문장별 출처 · 학술논문 · 기간 필터

Felo (펠로)

최신 정보 수집 · 다국어 지원

프롬프트 예시

[내 주제] 에 대해 최근 1 년 이내 자료만 찾아줘 .
공식 기관 · 언론 출처를 링크와 함께 표로 정리하고 ,
확실하지 않은 내용은 '확인 불가' 로 표시해줘 .
※ 도구는 후보를 찾아 줄 뿐 , 사실을 보증하지 않습니다 .

예시 — 같은 질문 , 이렇게 확인한다

입력한 질문
2026 년 적용 최저임금에 대해 최근 1 년 이내 자료만 찾아줘 . 공식 기관 · 언론 출처를 링크와 함께 표로 정리하고 , 확실하지 않은 내용은 '확인 불가' 로 표시해줘 .

확인 항목	검색에서 나온 내용	출처 (날짜)	내가 확인한 것
시간급	10,320 원 (전년 대비 2.9% 인상)	언론 보도 (2025.7.11)	보도마다 같은 숫자 ✔️
월 환산액	2,156,880 원	언론 보도 (2025.7.11)	10,320 원 × 209 시간 = 2,156,880 원 ✔️ 직접 계산
적용 연도	같은 검색에 2027 년 적용 10,700 원도 함께 나옴	언론 보도 (2026.7.15)	연도가 섞임 — 2026 년 적용분과 2027 년 적용분을 구분
공식 출처	고용노동부 보도자료 · 고시 페이지가 검색됨	고용노동부 누리집	본문은 열어서 직접 대조 (자동 접근 제한 사이트)

강의 준비 중 웹 검색으로 실행한 예시입니다 (2026.10.10). 도구와 시점에 따라 결과는 달라지므로 , 오늘은 내 질문으로 직접 비교합니다 .

같은 질문을 세 도구에 넣고 함께 비교한다

1	**질문 쓰기** 내 아이템으로 질문 한 문장을 쓴다 — 방금 본 요령을 적용
2	**세 도구에 입력** 같은 질문을 Perplexity·Liner·Felo 에 그대로 넣는다
3	**기록하기** 도구별 답 · 출처 · 날짜를 기록표에 적는다
4	**직접 확인** 출처 링크를 열어 답이 실제로 있는지 , 날짜 · 수치가 맞는지 대조한다
5	**함께 정리** 도구마다 다른 점 , 틀린 점을 같이 찾아 발표한다

AI 검색으로 수집하면 부딪히는 한계

1	**요약하다 틀린다** AI 는 원문을 요약 · 재서술해 보여 준다 — 그 과정에서 내용이 달라질 수 있다
2	**출처가 불안정하다** 링크와 내용이 맞지 않거나 , 홍보 · 블로그 글이 함께 섞인다
3	**매번 결과가 달라진다** 같은 질문도 실행할 때마다 달라져 같은 조건으로 재현할 수 없다
4	**날짜 · 연도가 섞인다** 오래된 자료나 다른 연도 자료가 함께 나온다 (예시 : 2026 년 ·2027 년 최저임금)
5	**원문과 기록이 남지 않는다** 원문 그대로 저장되지 않고 , 수집일시 기록과 표 정리 · 대량 수집이 어렵다

정리 — AI 는 후보를 찾고 , 근거는 직접 수집한다

1

AI 검색의 역할

후보와 링크를 모으는 데까지 — 확인 전까지는 ‘단서’

2

1 차 출처로 확인

공식 사이트 · 원문에서 직접 대조한다 (⑤ 팩트체크)

3

직접 수집

원문을 그대로 가져오고 출처 · 수집일시를 남긴다 — 지금부터 실습

왜 구글시트로 수집하는가

코드 불필요

함수 하나 (=IMPORTXML) 만 셀에 입력하면 끝 — 별도 프로그램 설치 · 실행 없음

함께 직접 해보기

함께 URL 과 추출 위치 (XPath) 를 직접 찾아 입력 — 한 번 익히면 다른 페이지에도 응용 가능

결과가 바로 표 형태

수집한 데이터가 셀에 바로 채워져 정제 · 필터링이 쉬움

무료

구글 계정만 있으면 별도 비용 없이 사용 가능

IMPORTXML 함수 사용법

=IMPORTXML(url , xpath_query)

url

데이터를 가져올 웹페이지 주소 (따옴표로 감싸기)

xpath_query

페이지에서 추출할 위치를 지정하는 경로 — 크롬 개발자도구에서 요소 우클릭 → ‘ Copy XPath’ 로 얻을 수 있음

주의 : xpath 와 url 모두 큰따옴표 (") 로 감쌉니다 . 작은따옴표 (') 가 필요한 경우는 xpath 안에 속성값 (예 : @id=' 내용 ') 이 있어 따옴표가 또 필요할 때뿐입니다 — //h1 처럼 단순한 경로는 큰따옴표만으로 충분합니다 .

실습 중 자주 만나는 문제

#N/A 오류

xpath 가 실제 페이지 구조와 다름 — 페이지 구조가 바뀌었거나 요소 선택이 틀림

따옴표 오류

속성값이 있는 xpath(예 : [@id="..."]) 를 그대로 붙여넣어 큰따옴표가 겹칠 때 발생 — 안쪽만 작은따옴표로 교체 . 단순 경로 (//h1 등) 는 큰따옴표만 쓰면 됨

‘ 로드하는 데 시간이 걸림’

시간당 호출 제한 초과 — IMPORTXML 개수를 줄이거나 잠시 후 재시도

빈 결과

자바스크립트로 나중에 그려지는 동적 페이지 — IMPORTXML 은 정적 HTML 만 읽을 수 있음

실전에서 확인한 사이트별 접근성

연합뉴스
차단

홈페이지·RSS 모두 자동 접근 차단 (robots.txt)

한국소비자원
차단

사이트 자동 접근 차단 — 시트 함수 대신 브라우저 기반 수집 (TOP5 자료) 으로 진행

정책브리핑 (korea.kr)
가능

실제 IMPORTXML 성공, 텍스트 공공누리 자유이용

식품의약품안전처
가능

실제 접근 확인됨, 리콜·안전 정보 다수

기상청 날씨누리
가능

공식 예보문, 공공저작물

직접 테스트해보지 않으면 알 수 없습니다 — 같은 정부 사이트라도 차단 여부가 다릅니다.

핵심 원칙

합법적 AI 데이터 활용 3 원칙

① 합법적 수집 구분 → ② AI 기반 정제 → ③ 사람의 검수

가능 — AI 로 자유롭게 정제

- 공공데이터포털 · 보도자료
- 증시 · 경기 등 사실 수치
- 위키백과 , 공유마당 (CCL)
- 본인이 직접 생산한 콘텐츠

제한 — 사실만 뽑아 내 문장으로

- 언론사 기사 본문 (AI 에 넣지 않기)
- 유료 구독 콘텐츠
- AI 학습 · 활용 금지 명시 저작물
- ‘변경금지’ 조건의 공공누리

IMPORTHTML · IMPORTFEED 도 함께 알아두기

IMPORTHTML

=IMPORTHTML(url, “table” 또는 “ list”, 순번)

페이지 안의 표나 목록을 통째로 가져올 때
— xpath 보다 훨씬 간단

IMPORTFEED

=IMPORTFEED(url)

언론사 · 블로그의 RSS 주소만 있으면 최신 글 목록을 자동 수집

AI 검색이 아니라 코딩으로 수집하는 이유

요약 단계가 없다

원문 데이터를 그대로 가져온다 — 앞에서 본 요약 · 결론 오류가 구조적으로 생기지 않음

출처 · 수집일시 저장

어디서 언제 가져왔는지 열로 남겨 나중에 다시 확인할 수 있음

재현 가능

같은 코드를 다시 돌리면 같은 조건으로 같은 결과가 나옴

점검 가능

오류가 없어지는 것이 아니라 , 어디서 틀렸는지 찾아 고칠 수 있게 됨

코딩으로 수집하는 4 가지 방법

공식 API

포털 검색 API(네이버), 국가법령정보 · 공공데이터포털 — 가장 먼저 검토

RSS

언론사 · 기관이 제공하는 최신 글 목록 — 구조가 정해져 있어 안정적

웹 스크래핑

API·RSS 가 없을 때만 — robots.txt 와 이용약관을 먼저 확인

AI 검색 API

후보 발굴용 — 결과는 근거가 아닌 단서로 저장하고 원문과 대조

Colab 에서 API 로 데이터 가져오기

requests.get(url , headers= 헤더 , params= 조건)

headers

인증키 (Client ID·Secret) — 코드에 직접 쓰지 않고 Colab 보안 비밀 (Secrets) 에 저장

params

검색어 (query), 가져올 건수 (display), 정렬 (sort) 등 — 응답은 JSON, 표 (DataFrame) 로 바꿔 저장

참고 : 코드는 AI 와 함께 작성하되 , 직접 실행해 결과를 확인합니다 . 저장할 때 출처 URL· 수집일시 열을 꼭 추가합니다 .

코딩 수집에서 지킬 4 가지

인증키 보관

코드에 직접 쓰지 않는다 — Colab 보안 비밀 (Secrets) 에 저장하고 공유 시 제외

호출 예의

호출 제한을 지키고 , 짧은 간격으로 반복 호출하지 않는다

약관 ·robots.txt

허용된 범위에서만 수집 — 기사 본문 등은 앞의 3 원칙 (저작권) 을 함께 확인

기록

출처 URL· 수집일시 · 검색 조건을 열로 남겨 팩트체크 때 다시 확인

학생별 API 키 발급, 이렇게 합니다

① 가입 · 본인 인증

네이버 개발자센터, 공공데이터포털, 국가법령정보 공동활용 — 서비스마다 각자 가입

② 등록 · 활용신청

사용할 API를 고르고 사용 목적 입력 — 승인이 필요한 서비스는 사전에 신청

③ 키 확인

네이버 : Client ID·Secret /
공공데이터포털 : 인증키 (Encoding·Decoding) / 법령 : OC 값

④ 테스트 호출

Colab에서 한 건만 호출해 응답 확인 — 안 되면 승인 상태 · 키 값 · 한도 순으로 점검

키는 내 비밀번호처럼 다룹니다

학생별 개별 발급

키는 개인 계정에 묶여 있음 — 공용 사용 · 타인에게 전달 금지

노출 금지

코드 · 슬라이드 · 공유 노트북에 직접 쓰지 않고 Colab 보안 비밀 (Secrets) 에 저장 , 유출 시 즉시 재발급

호출 한도

서비스마다 일일 한도가 있음 — 한 건으로 먼저 테스트하고 반복 호출에는 간격을 둔다

약관 · 개인정보

이용 약관 확인 , 수집 결과의 실명 등 개인정보는 필요한 항목만 저장 · 공유 전 점검

정제란 무엇이었는지 복습

2 주차에서 만든 챗봇을 이번주는 실제 수집 자료로 돌려 봅니다 .

Gemini Gems

무료 · 구글 계정

Claude Projects

Pro 이상 유료

이번주는 새로 만들지 않고 , 2 주차에 만든 내 도메인 챗봇에 ‘수집한 데이터’ 를 넣어 정제된 콘텐츠를 뽑아냅니다 .

② + ③ 연결

오늘 실습 흐름 — 수집에서 정제까지

1
구글시트 IMPORTXML 로 데이터 수집

2
수집한 표를 복사

3
AI 챗봇에 붙여넣기

4
정제 프롬프트 (역할 · 구조 · 톤) 지정

5
완성된 콘텐츠 확인

2 주차 ‘도메인별 프롬프트 가이드’ 의 템플릿을 그대로 재사용합니다 . (챗봇은 새로 만들지 않습니다)

오늘의 실습

수집 → 정제 , 손으로 직접 해보기

Part A. 구글시트로 지정된 페이지에서 데이터 수집하기
Part B. 저작권 유형을 확인한 뒤 , 2 주차 도메인 챗봇으로 정제해 콘텐츠 완성하기
Part C. Colab 에서 AI 와 함께 API 호출 코드를 작성 · 실행하고 , 결과표를 출처 · 수집일시와 함께 저장하기

다음 주 예고

4 주차 — 도메인에 맞는 뉴스 세팅하기 (3/3)
도메인별 파인튜닝 , AI 생성물 검수 · 품질개선 [③ 완료 120h]