합법적 AI 데이터 활용 3 원칙

3 주차 실습에서 확인한, 과정 전체를 관통하는 핵심 원칙

왜 이 원칙이 필요한가

연합뉴스 같은 통신사는 뉴스를 방송사·신문사에 유료로 공급(신디케이션)하는 것이 핵심 수익 구조입니다. 누구나 AI 로 그 기사를 무단 요약·재가공할 수 있다면 정당하게 비용을 지불하는 언론사와의 형평성이 깨지고, 취재 활동을 지탱하는 수익 기반 자체가 흔들립니다. 이 제약은 AI 활용을 막으려는 것이 아니라 콘텐츠 원 생산자를 보호하려는 조치입니다.

실제로 문화체육관광부·한국저작권위원회는 2025 년 12 월 발표한 「생성형 AI 의 저작물 학습에 대한 공정이용 안내서」에서, 언론 기사 원문을 AI 에 학습시켜 요약 서비스를 제공하는 방식은 저작권자 동의 없이는 저작권법 위반 소지가 크다고 공식 해석했습니다.

3 단계 원칙

① 합법적 수집 구분 능력

어떤 데이터는 AI 로 자유롭게 다뤄도 되고, 어떤 데이터는 안 되는지 구분하는 판단력을 기른다. 이 판단이 파이프라인의 출발점이다.

② AI 기반 정제

①을 통과한(합법적으로 이용 가능한) 데이터는 AI 로 적극적으로 정제·재구성한다.

③ 사람의 검수

AI 가 자동 생성한 결과물은 반드시 사람이 사실관계와 표현을 검수한 뒤 사용한다.

이 3 단계는 마스터 문서의 파이프라인(① 수집→②정제→③팩트체크)과 같은 구조입니다 — 다만 이번 실습을 통해 ①수집 단계에서부터 합법성을 먼저 걸러야, ② 정제 단계에서 AI 를 안전하게 쓸 수 있다는 것을 구체적으로 확인했습니다.

① 판단 기준 — 무엇이 가능하고 무엇이 제한되는가

가능 — AI 로 자유롭게 정제	제한 — AI 정제 금지, 사람이 직접 읽고 재구성
공공데이터포털(data.go.kr) 통계·수치	연합뉴스 등 언론사 기사 본문
정부·지자체 보도자료 원문	유료 구독 콘텐츠
증시 시세, 경기 스코어 등 사실 수치	상업용 이미지·유료 음원
위키백과, 공유마당(CCL) 콘텐츠	AI 학습·활용 금지가 명시된 모든 저작물
학생이 직접 취재·인터뷰한 내용	

판단 근거

- 가능한 쪽: 사실·수치·정형데이터이거나, 저작권이 없거나(공공저작물), 자유이용이 명시된 콘텐츠(CCL 등), 또는 본인이 직접 생산한 콘텐츠
- 제한되는 쪽: 언론사·창작자가 취재·집필한 표현물로, 저작권이 있고 AI 학습·활용을 명시적으로 금지하거나 상업적 대가가 필요한 콘텐츠
- 판단이 애매할 때는 콘텐츠 하단이나 이용약관에서 저작권 표시 문구를 직접 확인하는 것이 가장 확실하다

이 원칙이 실습에 적용되는 방식

- ① 수집: 구글시트 IMPORTXML 로 데이터를 모을 때, 그 출처가 위 표의 '가능' 쪽인지 먼저 확인한다
- ② 정제: '가능' 쪽 데이터는 AI 챗봇(GPTs·Gemini Gems·Claude Projects)으로 자유롭게 다듬는다. '제한' 쪽이라면 사람이 먼저 읽고 재구성한 글을, AI 는 그 글의 표현만 다듬는다
- ③ 검수: AI 가 만든 결과는 항상 사람이 사실 확인 후 발행한다 — 이는 데이터 종류와 무관하게 항상 적용되는 마지막 단계