[수업 사례 자료 · **2026-10-14**]

[MBC 미디어캠퍼스**] AI** 기반 데이터 저널리스트 양성 과정

정제 → 스크립트화 → 팩트체크

1 인가구 비중 사례로 보는 **7** 단계 파이프라인 실습 예시

1. 이 사례를 만든 이유

1 주차 강의안의 7 단계 파이프라인은 원래 "① 기획-② 수집-③ 정제-④ 인사이트분석-⑤ 팩트체크-⑥ 스크립트화-⑦ 영상화" 순서였다. 그런데 정제데이터는 곧바로 스크립트 작성 챗봇(젬스·Gemini Gems)에 투입되므로, 스크립트화가 먼저 이뤄지고 그 다음에 팩트체크가 와야 한다. 또한 팩트체크 과정에서 스크립트화 단계가 새로 만들어낸 오류(원본 데이터에는 없던, AI 가 대본을 쓰면서 생긴 오류)를 잡아낼 수 있어야 한다. 아래는 이 수정된 순서(정제 → 스크립트화 → 팩트체크)를 실제 데이터로 실습해 본 결과다.

2. 실습 흐름

단계	내용
③ 정제데이터	1 인가구 비중 정제데이터 2 종 — one_person_household_ratio_pivot.csv(지역×연도 피벗), one_person_household_summary_2015_2025.csv(지역별 2015·2025 비교+증가폭)
⑤ 스크립트화	정제데이터를 Gemini Gems "방송뉴스원고작성봇"에 투입 → 앵커멘트+리포트 본문+클로징 형식의 방송뉴스 원고 초안 생성
⑥ 팩트체크	생성된 원고 속 숫자·연도·순위 주장을 코랩(Python/pandas)으로 정제데이터와 자동 대조 — 코드 분석을 원칙으로 함

3. 팩트체크 결과

총 11 개 항목을 자동 대조한 결과 10 개 일치, 1 개 불일치가 발견되었다.

[일치 10 건] 전국·대전·서울·강원 비중 수치, 대전·서울 증가폭(%p), 증가폭 순위 1 위·2 위(대전·서울), 40% 초과 지역 목록, 총가구수·1 인가구수 만 단위 환산 — 모두 정제데이터와 정확히 일치

[불일치 1 건] **"2020** 년 **31.7%**로 **30%**를 넘어선**"** 이라는 문장

항목	원고 주장	실제 정제데이터
전국 **1** 인가구 비중 **30%** 최초 돌파 연도	2020 년 (31.7%)	2019 년 (30.2%) — 2020 년은 이미 31.7%로, 전년도에 이미 30%를 넘은 뒤였음

원고가 돌파 시점을 1 년 늦게 기술한 사실 오류다. 2015~2025 년 전국 수치를 연도순으로 훑어보면 2015 년 27.2% → 2019 년 30.2% 로 처음 30% 를 넘고, 2020 년 31.7% 로 이미 30% 를 넘은 상태였다. 단일 연도 수치 대조만으로는 잡히지 않고, "처음 넘은 해가 언제인가"라는 연쇄 비교를 해야만 발견되는 유형의 오류다.

4. 이 사례가 보여주는 것

4-1. 팩트체크는 왜 코드로 해야 하는가

같은 질문(AI 에게 "이 숫자 맞아?"라고 다시 묻기)을 반복해도, 대본을 쓴 AI 와 검수하는 AI 가 같은 유형의 착각(연도 임계값을 잘못 읽는 것)을 똑같이 반복할 수 있다. 코드 기반 대조는 정제데이터를 그대로 불러와 조건식으로 연산하기 때문에, 반복 가능하고(reproducible), 결정적이며(deterministic), 숫자 규모에 영향받지 않는(scale-invariant) 검증이 가능하다. 이것이 "팩트체크는 코드 분석을 원칙으로 한다"는 수업 원칙의 실제 근거다.

4-2. 왜 정제 → 스크립트화 → 팩트체크 순서여야 하는가

이번 오류는 원본 정제데이터에는 없던 것으로, 스크립트화(AI 가 대본을 쓰는) 단계에서 "30%를 넘은 해"를 잘못 계산하며 새로 생긴 오류다. 만약 팩트체크를 스크립트화보다 먼저 했다면(기존 순서), 대본이 만들어지기 전이므로 이 오류 자체가 존재하지 않아 검증 대상이 될 수 없었다. 즉 팩트체크는 반드시 스크립트화 다음에 와야, 스크립트화 단계가 만들어낸 오류까지 잡아낼 수 있다.

4-3. 학생 실습 포인트

- 정제데이터를 먼저 확인하지 않고 결과(원고)만 보면 오류를 알아챌 수 없다 — 반드시 숫자 하나하나를 원본과 대조해야 한다.
- [illegible](✅/❌)[illegible], "[illegible] OO[illegible]", "1[illegible]·2[illegible] [illegible]", "OO [illegible] [illegible] [illegible] [illegible]" [illegible] [illegible]·[illegible] [illegible] [illegible] [illegible] [illegible] [illegible] [illegible] [illegible] [illegible].
- 코랩 노트북은 원고를 통째로 triple-quote 문자열로 붙여넣고, 정규식으로 숫자를 추출한 뒤 pandas 로 대조하는 방식으로 재사용 가능한 템플릿화가 가능하다.

5. 정정 전/후 비교

구분	문장
정정 전 (오류)	"지난 2015 년 27.2%였던 전국 1 인 가구 비중은 해마다 증가세를 이어왔습니다. 2020 년 31.7%로 30%를 넘어선 데 이어, 2025 년에는 36.6%까지 치솟았습니다."
정정 후 (수정 제안)	"지난 2015 년 27.2%였던 전국 1 인 가구 비중은 해마다 증가세를 이어왔습니다. 2019 년 30.2%로 처음 30%를 넘어선 데 이어, 2025 년에는 36.6%까지 치솟았습니다."

6. 참고 — 사용한 정제데이터 요약

지역	2015 비중	2025 비중	증가폭(%p)
전국	27.2%	36.6%	9.4
대전	29.1%	40.3%	11.2 (전국 1 위)

서울	29.5%	40.5%	11.0 (전국 2 위)
강원특별자치도	31.2%	40.1%	8.9

전국 수치가 처음 30% 를 넘은 해: 2019 년(30.2%) — 2015~2025 년 연도별 수치: 27.2 · 27.9 · 28.6 · 29.3 · 30.2 · 31.7 · 33.4 · 34.5 · 35.5 · 36.1 · 36.6